

Project NVISIA

North Korea Visual Insight with SIA

Team NVISIA

발표자: 천승우



Team Members

- 천승우
- 손호진
- 정소민
- 진용현

GitHub Project Repository:

<https://github.com/milkpotato1000/NVISIA>

Mentor: 함상우 (SIA)



목차

Project NVISIA

01. 프로젝트 개요

- Project NVISIA 시작 배경
- NVISIA 서비스 기술 스택

02. 워크플로우

- NVISIA 서비스의 흐름

03. 데이터

- 원천데이터 및 수집 방법

04. 서비스 개발 핵심 전략

- Input to DB (I2D)
- DB to Dashboard (D2D)

05. 결과 및 발전 방향

- NVISIA 서비스 개발 결과
- 향후 발전 계획

➤ 문제 진단

: 북한 이슈 수집/통합 및 파악의 어려움

- 폐쇄국가인 북한 관련 **자료 확보**의 어려움
- 핵심 이슈 관련 **정보 요약 및 파악**의 어려움
- 다양한 출처 문서의 **통합 관리 및 조회**의 어려움



➤ 문제 해결 방안

: 실효성 있는 북한 관련 정보 **통합/조회** 시스템 구축

OSINT

- Open-Source Intelligence 문서 수집 및 활용
 - **수집/활용 가능한 문서** 수집 및 전처리

GIS

- 문서 내 주요 **위치정보** 추출 및 시각화
 - 북한 행정구역(시, 도) 경계면(polygon) 좌표 데이터 활용
 - 북한 주요시설 좌표 데이터(단일 위도/경도) 활용

추천시스템

- 선택 문서의 **사건 유사도** 기반 문서 추천
 - 추천 문서 사이 키워드 관계도(**Knowledge Graph**) 제공

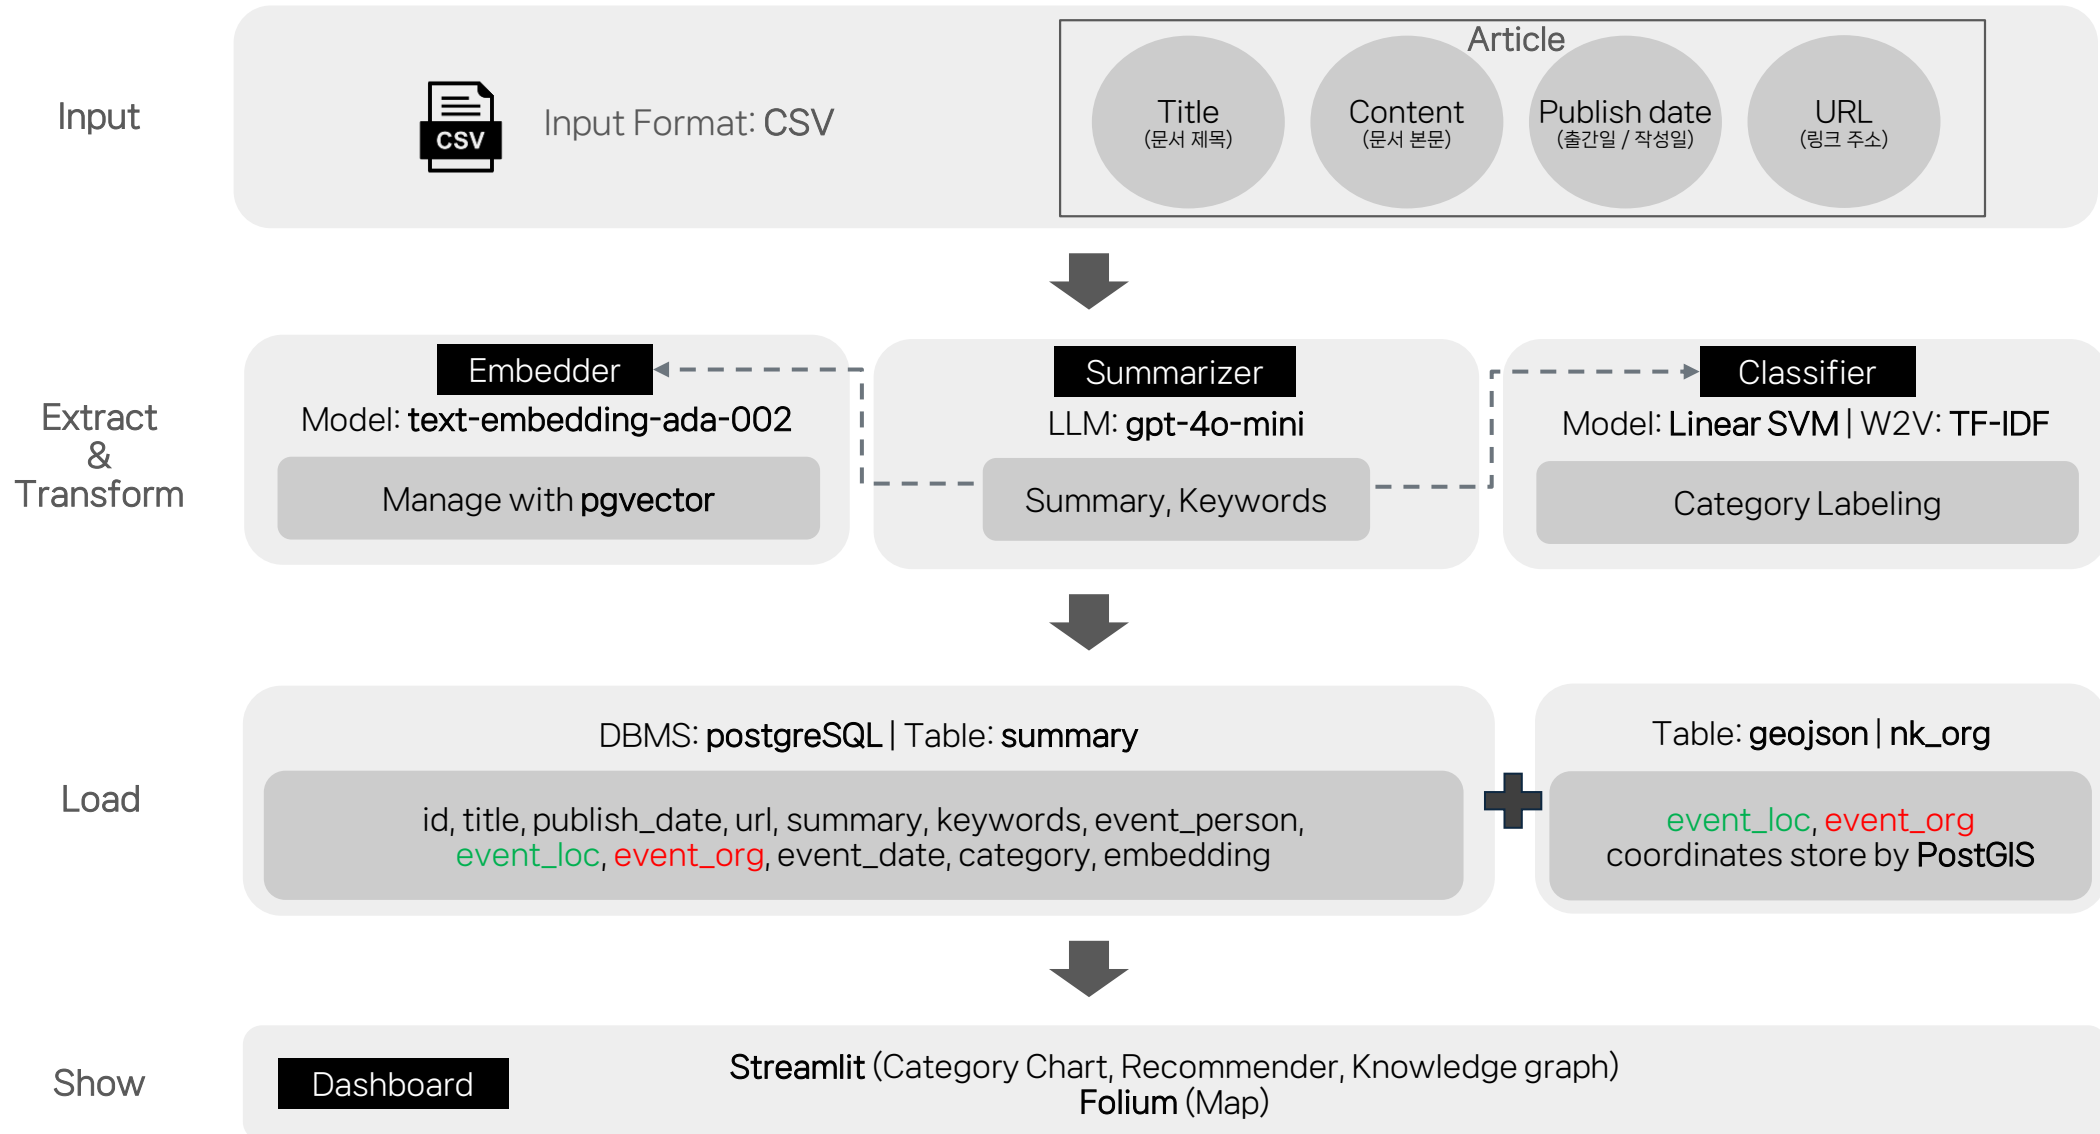
➤ 서비스 타겟

: 정보 수집 후 **요약 및 통합 조회**에 어려움을 겪는 사람 / 단체

(예) 북한 연구자, 안보 전문가, 기자, etc.



Data ETL	Machine Learning	Visualization	Dashboard
BeautifulSoup		matplotlib	
OpenAI	scikit learn	NetworkX Network Analysis in Python	Streamlit
PostgreSQL		Folium	



문서 Source → Rule-Based Crawling → 정보추출 및 정규화




BeautifulSoup

```
HTML
<script>...</script>
<!-- 기사면 상단 네비게이션 //-->
<div id="sticky-header" class="...>
  <!-- 기사면 상단 네비게이션 -->
  <!-- 기사본문 상단 //-->
  <header class="article-view-header">
    <!-- breadcrumbs //-->
    <nav role="navigation">
      <ul class="breadcrumbs">
        ::before
        <li>...</li>
        <li>...</li>
        <li>
          <a href="https://www.spnews.co.kr/news/articleList.html?sc_sub_section_code=S2N17&view_type=sm">정치</a> => $0
        </li>
        ::after
      </ul>
    </nav>
    <h1 class="heading">北 '당항건 80돌' 노동신문 등 공동사설...'국가 전면적 발전·사회주의 위업 완수'</h1>
    <!-- information // -->
    <div class="info-group">...</div>
  </header>
  <!--// 기사본문 상단 -->
  <section id="articleViewCon" class="article-view-content" data-mutate="2mb7dn-sticky" data-events="mutate">
    <article class="grid body">
      <div id="snsAnchor" class="sticky-article" data-mutate="ew4dw-w-sticky" data-events="mutate">
```




19,141개의 뉴스 샘플 수집



[SPN 서울평양뉴스: <https://www.spnews.co.kr/>]

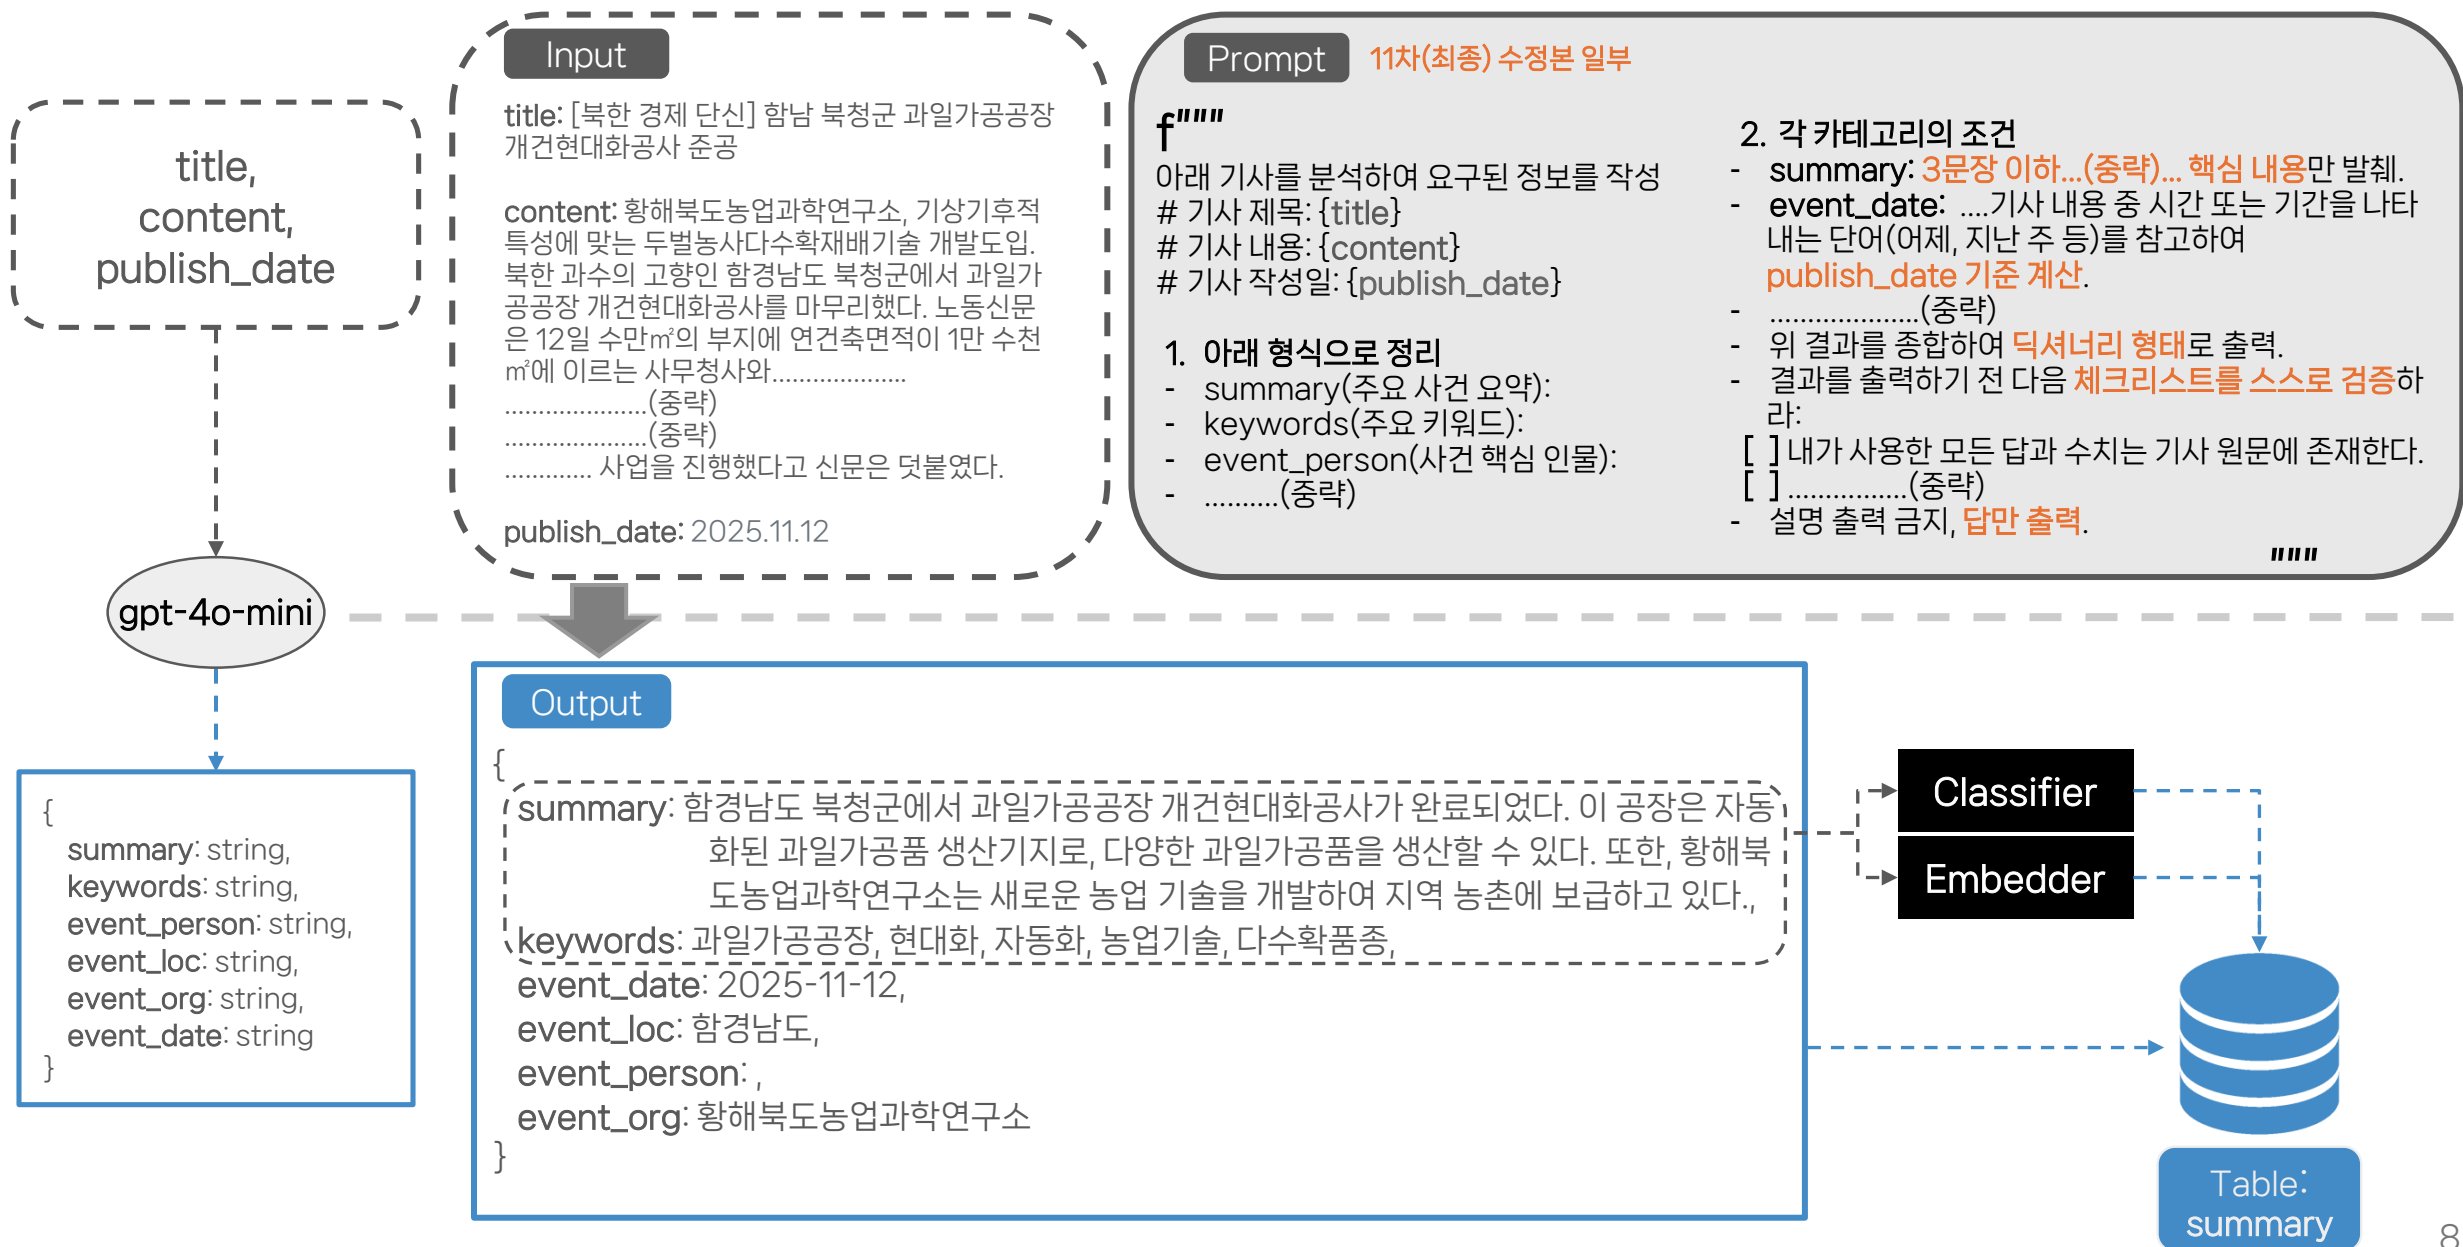
04. 서비스 개발 핵심 전략

- Input to DB (I2D)
- DB to Dashboard (D2D)



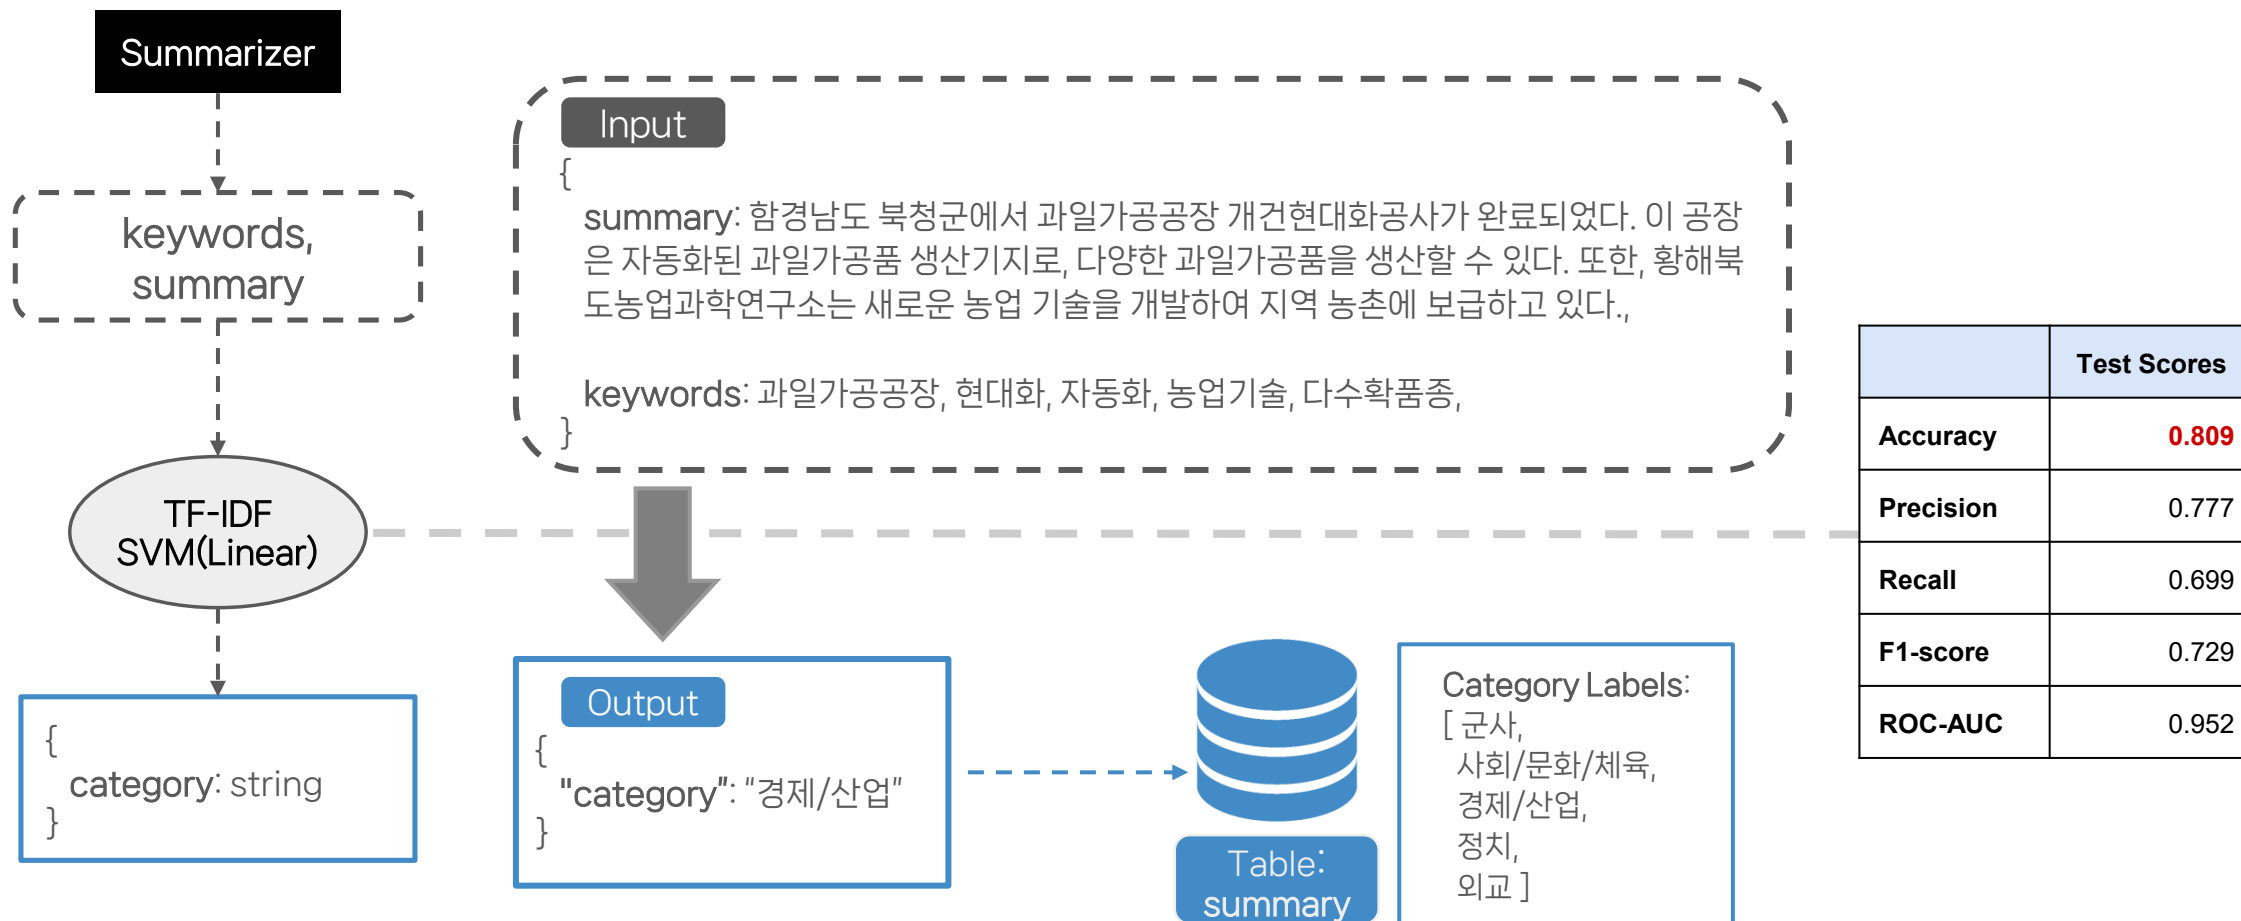
04. 서비스 개발 핵심 전략: Summarizer

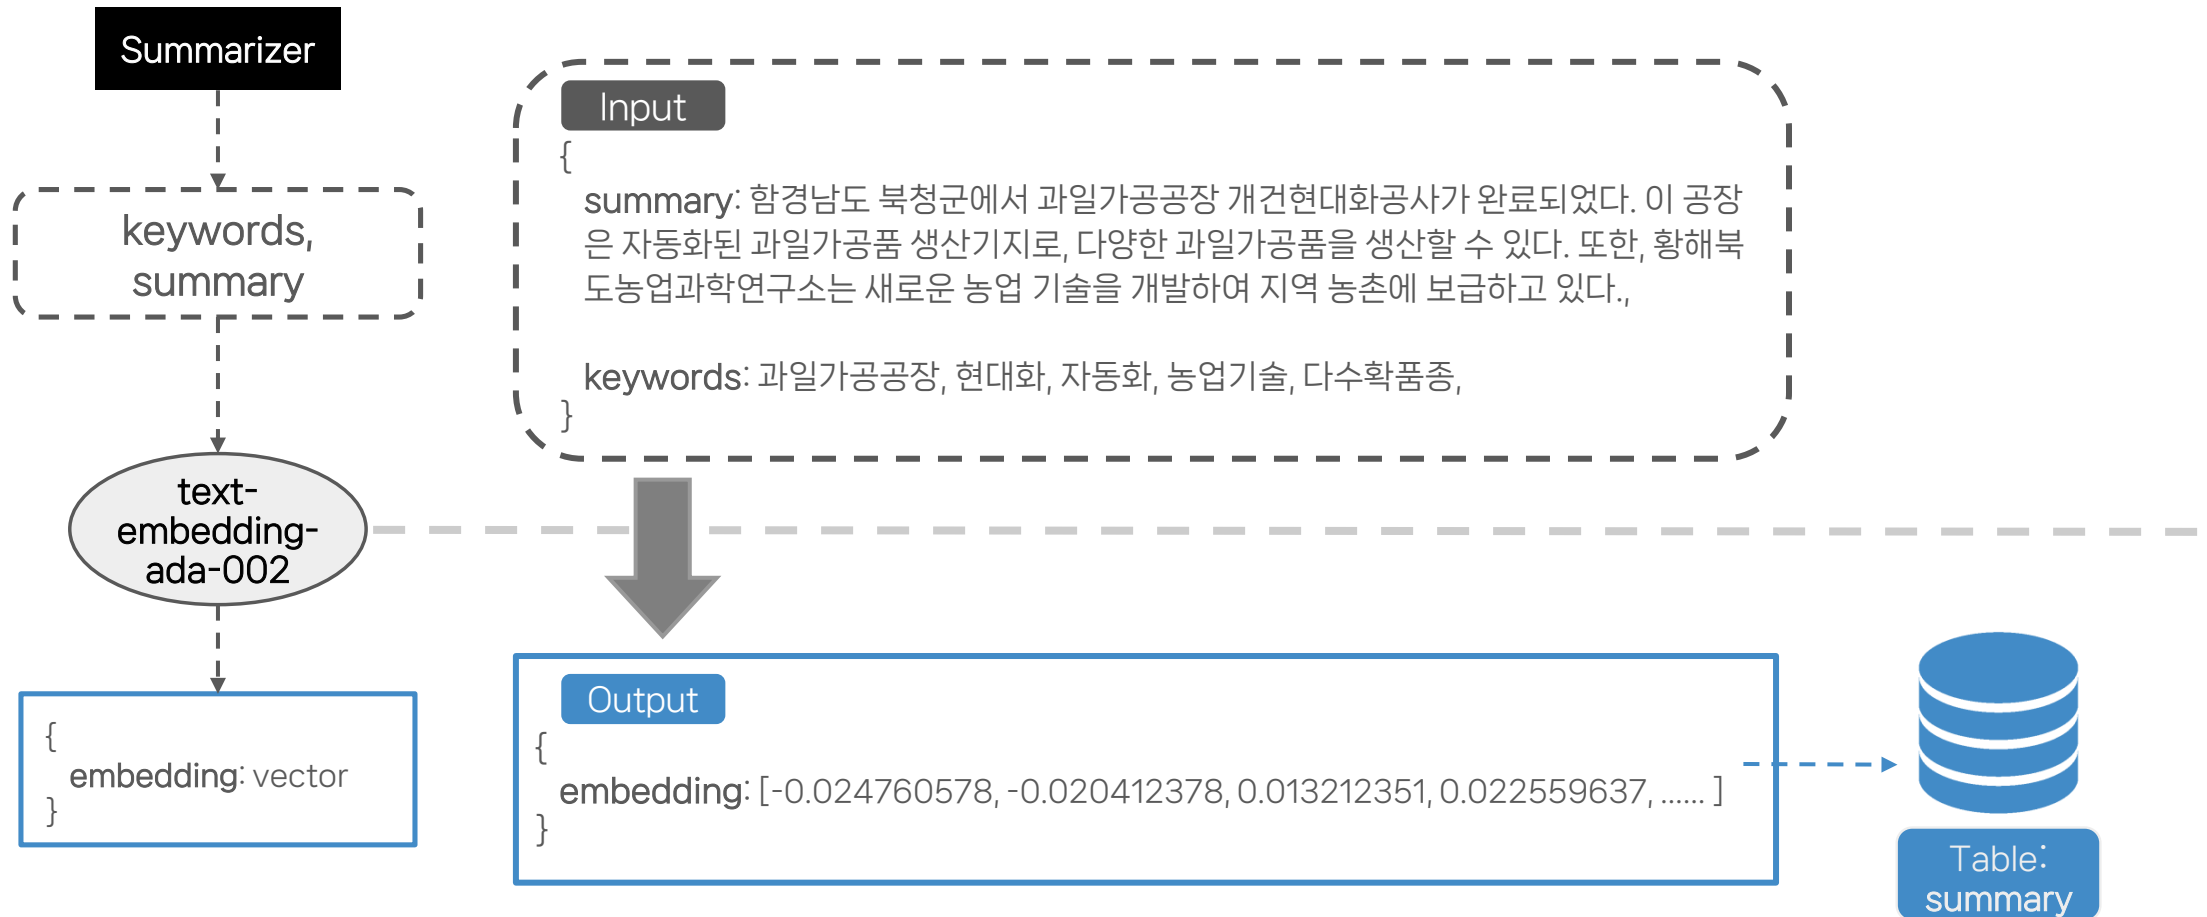
- Input to DB (I2D)
- DB to Dashboard (D2D)



04. 서비스 개발 핵심 전략: Classifier

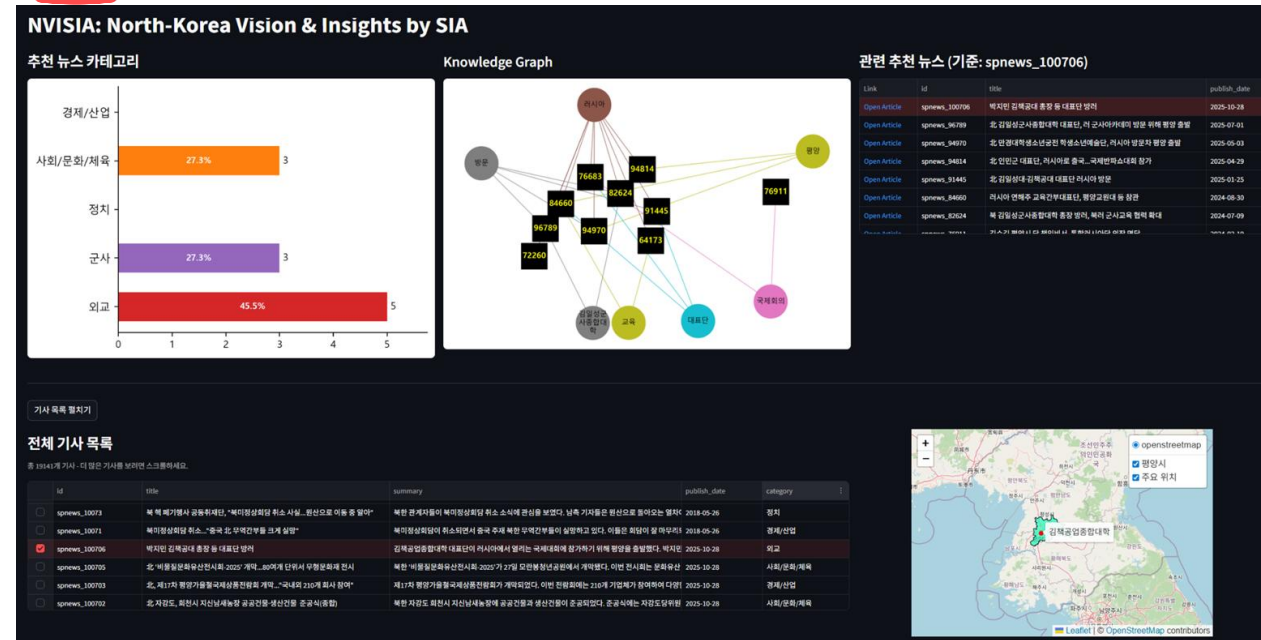

- ❑ Input to DB (I2D)
- ❑ DB to Dashboard (D2D)






04. 서비스 개발 핵심 전략

- Input to DB (I2D)
- DB to Dashboard (D2D)




04. 서비스 개발 핵심 전략: Recommendation

- ❑ Input to DB (I2D)
- ❑ DB to Dashboard (D2D)



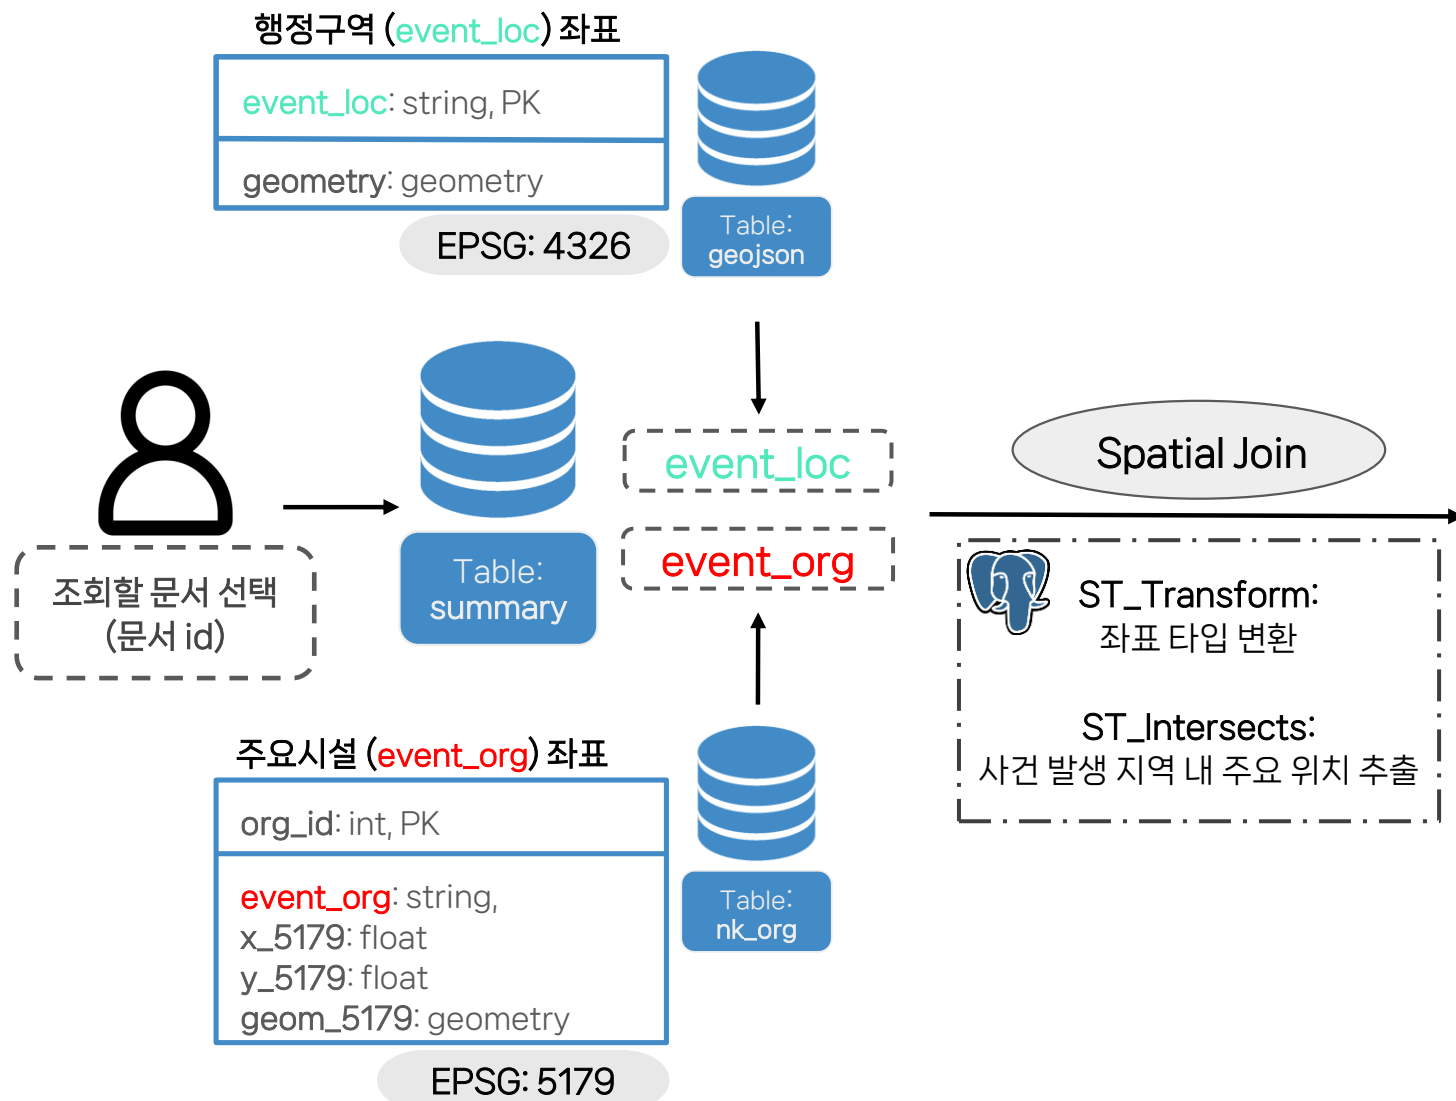
04. 서비스 개발 핵심 전략: Knowledge Graph

- Input to DB (I2D)
- DB to Dashboard (D2D)




04. 서비스 개발 핵심 전략: GIS

- Input to DB (I2D)
- DB to Dashboard (D2D)



Folium


Layer 1: 사건 발생지역(event_loc)



Layer 2: 주요시설(event_org)



사건 발생지역 & 주요시설




05. 결과 및 발전 방향: 대시보드


- NVISIA 서비스 개발 결과
- 향후 발전 계획

NVISIA: North-Korea Vision & Insights by SIA

추천 뉴스 카테고리



Knowledge Graph



관련 추천 뉴스 (기준: spnews_99888)


Link	id	title	publish_date
Open Article	spnews_99888	"사거리 교통 대기 시간 30% 줄인다"...북한도 '알고리즘' 곳곳에 활용	2025-10-02
Open Article	spnews_85660	북 함경남도 함흥시, 교통운수수단 개선 운영 시작	2024-09-27
Open Article	spnews_78665	북, 평양 문수-토성행 레도전자노선+무레도전자노선 전환 공사	2024-04-06
Open Article	spnews_68092	北 전국철도운수부문 과학기술발표회...여객열차 시설개선 토론	2023-07-15
Open Article	spnews_61051	北 김책공대, 탄광 경도 진자선 이용한 통신체계 개발	2023-01-28
Open Article	spnews_44758	평양고통문수대학, 이온교육-실험실습교육 강화	2021-10-20
Open Article	spnews_37778	北 평양여객운수부문, "대중교통수단 기술개선사업 추진"	2021-03-21
Open Article	spnews_37778	北 평양여객운수부문, "대중교통수단 기술개선사업 추진"	2021-03-21

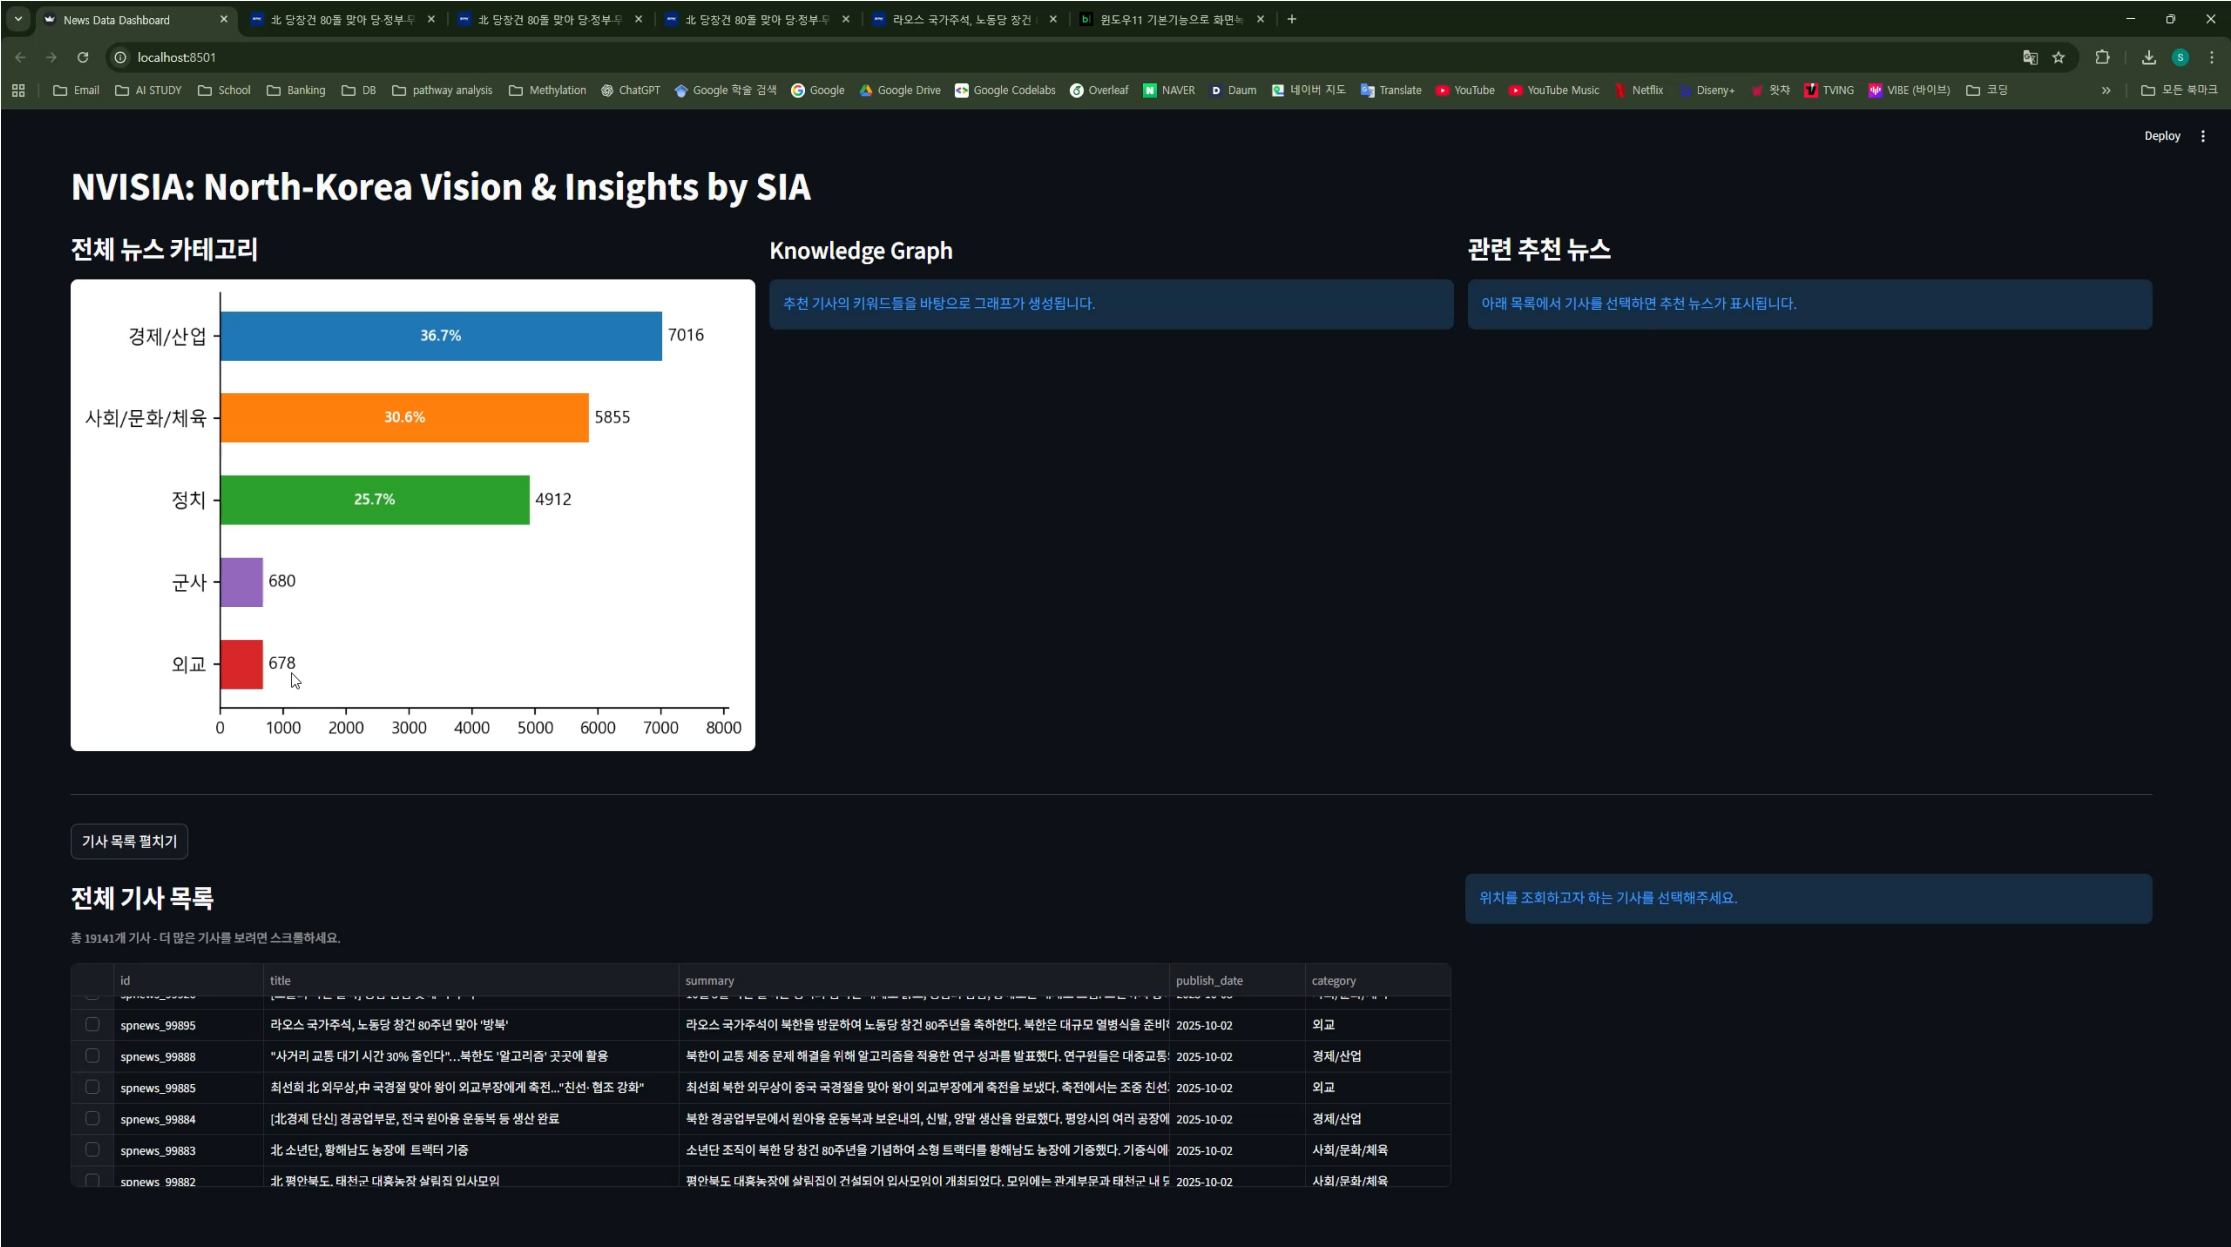
기사 목록 펼치기

전체 기사 목록

총 19141개 기사 - 더 많은 기사를 보려면 스크롤하세요.

	id	title	summary	publish_date	category
☐	spnews_99895	러오스 국가주식, 노동당 창건 80주년 맞아 '양복'	러오스 국가주식이 북한을 방문하여 노동당 창건 80주년을 축하한다. 북한은 대규모 열병식을 준비	2025-10-02	외교
☒	spnews_99888	"사거리 교통 대기 시간 30% 줄인다"...북한도 '알고리즘' 곳곳에 활용	북한이 교통 체증 문제를 해결을 위해 알고리즘을 적용한 연구 성과를 발표했다. 연구원들은 대중교통	2025-10-02	경제/산업
☐	spnews_99885	최선희 北 외무상,中 국경철 맞아 왕이 외교부장에게 축전..."친선·협조 강화"	최선희 북한 외무상이 중국 국경철을 맞아 왕이 외교부장에게 축전을 보냈다. 축전에서는 조중 친선	2025-10-02	외교
☐	spnews_99884	[北경제 단신] 경공업부문, 전국 원아용 운동복 보은내의, 신발, 양말 생산을 완료했다. 평양시의 여러 공장에	북한 경공업부문에서 원아용 운동복과 보은내의, 신발, 양말 생산을 완료했다. 평양시의 여러 공장에	2025-10-02	경제/산업
☐	spnews_99883	北 소년단, 함해남도 농장에 트랙터 기증	소년단 조직이 북한 당 창건 80주년을 기념하여 소형 트랙터를 함해남도 농장에 기증했다. 기증식에	2025-10-02	사회/문화/체육
☐	sonews_99882	北 평안북도, 태천군 대흥농장 실험실 입사모임	평안북도 대흥농장에 실험실이 건설되어 입사모임이 개최되었다. 모임에는 관개부문과 태천군 내 도	2025-10-02	사회/문화/체육





05. 결과 및 발전 방향: 시연영상 (파일 업로드)

- ❑ NVISIA 서비스 개발 결과
- ❑ 향후 발전 계획

[CSV 파일 업로드 시연 영상]

1. YTN 기사 크롤링
 - 신규 기사 (북, 장거리전략순항미사일 발사 훈련)
 - 중복 기사 (북한, 고성 DMZ 인근에 신규 댐·발전소 건설)
 - Database에 동일한 기사 존재
 - 누락 기사 (김정은, 종이공장 준공식 참석...)
 - Content가 누락되어 있음
2. Dashboard 및 database 현황
3. CSV 파일 업로드
 - 신규 기사: 정상 업로드
 - 중복 기사: 업로드 실패
 - 누락 기사: 업로드 실패
4. Dashboard 및 database 변경 사항 체크

ytn_articles.csv [C:\Users\User\Desktop\MODULABS\Aiffelthon\시연영...]

A1	title
1	title content publish_durl
2	북, 장거리 북한이 서 2025.12.29 https://www.ytn.co.kr/_ln/0101_202512290651071624
3	"북한, 고성북한이 강 2025.11.29 https://www.ytn.co.kr/_ln/0104_202511290250369255
4	김정은, 종이공장 준공 2025.12.29 https://www.ytn.co.kr/_ln/0101_202512290852238667

➤ Summary

- 북한 이슈 관련 문서(뉴스) 수집 / 가공 / 적재
 - LLM활용 문서 내 주요 정보 추출 및 정규화
- 가공된 정보의 활용
 - Summary + Keywords 활용 문서 분류(ML 모델) 및 임베딩
 - 정보 수집/조회/시각화 UI 구현 (Dashboard)
- 추천 시스템
 - 임베딩 기반 유사도 검색을 통한 추천 문서 제공
 - 추천문서간 키워드 기반 연관성 시각화 (Knowledge Graph)

1. 공간정보 확장분석

◆ 현재

- DB 공간정보(지리, 기관) 단순 활용(단순 좌표 시각화)

◆ 개선 계획 및 예상 효과

- 동일 시간/기간 인접지역 발생 이슈 함께 참조
 - 1) 특정 사건 사실 여부 교차 검증
 - 2) 맥락 기반 정보 탐색

2. 인물 중심 분석 도입

◆ 현재

- DB의 "event_person" 활용 X

◆ 개선 계획 및 예상 효과

- 주요인물(예: 김정은)의 동선 시각화
 - 1) 군사이벤트의 연속성 분석
 - 2) 정권 행보 및 의사 결정 흐름 파악

3. 검색/필터링 기능 도입

◆ 현재

- 문서 검색/필터링 기능 X

◆ 개선 계획 및 예상 효과

- 고급 문서 검색 기능 도입 (ElasticSearch 등 활용)
 - 1) 사용자 정보 접근성 향상
 - 2) 검색을 통한 이벤트 주제, 지명, 기관 등 필터링 가능
 - 3) 오탈자, 동의어, 축약어 등 별칭을 통한 검색 가능

4. 전체 문서 Pagination

◆ 현재

- 전체(~19,200) 문서 대시보드 한 섹션에 모두 로딩
- 캐싱전 로딩에 수분 소요
- 과거 기사 조회를 위해서는 과도한 스크롤링 필요

◆ 개선 계획 및 예상 효과

- 전체문서 섹션 pagination
 - 1) 대용량 데이터 축적 대응
 - 2) 초기 로딩속도 개선
 - 3) 서버 부하 최소화




Project NVISIA

Thank You

Q & A





MODEL	INPUT	CACHED INPUT	OUTPUT
gpt-4o-mini	\$0.15	\$0.075	\$0.60

- 뉴스 요약 평균 비용: ~ \$0.0003 / news
- 10,000 news = \$3.00



```
# 토큰 사용량 조회
print(f'***토큰 사용량***\n입력: {input_tokens}\n출력: {output_tokens}')
print(f'-'*30)

# 전체 소비 토큰 가격 계산
costs = sum([(input_tokens * 0.15 / 1_000_000), (output_tokens * 0.60 / 1_000_000)]) # 가독성을 위해 1000단위 underscore(_) 사용
print(f'***Total Cost***\n${costs}')
```

✓ 0.0s

토큰 사용량

입력: 1085

출력: 175

Total Cost

\$0.00026775

🏠 홈 > 북한N > 경제/산업



[北 물가] 곡물류·수입식품·유류 가격, 큰 폭으로 올라

✎ 안윤석 대기자 | ⌚ 입력 2024.04.03 00:00 | 💬 댓글 0

<기준 문장>

- 이달 1일 기준 북한 장마당에서 거래되는 식용유(1kg) 가격은 11,000원 선으로 같은 양의 쌀값(5,000원)의 두 배다.

- 모델: gpt-4o-mini
- 요청: 평양 쌀 값 추출 (10회 반복)
 - {"rice_price": 11000} → 10회 오답
- 모델: gpt-4o
- 요청: 평양 쌀 값 추출 (10회 반복)
 - {"rice_price": 5000} → 10회 정답
- 모델: gpt-5
- 요청: 평양 쌀 값 추출 (10회 반복)
 - {"rice_price": 5000} → 10회 정답

Prompt 9차 수정본 일부 발췌

"rice_price":

"평양"의 쌀 가격 정보만을 추출하기 위함.

- 반드시 ****평양의 "쌀 1kg 가격"***이 정확하게 명시되어있는 경우만 추출,
- ****정수****로 입력.
- 평양 쌀 가격을 100% 단언 할 수 없는 경우 ****절대로 지어내지 말고**** 빈칸으로 남김.

Vectorization	Model	Accuracy	Precision	Recall	F1-score	ROC-AUC
TF-IDF	Logistic Regression	0.807	0.787	0.665	0.705	0.954
	SVM (Linear)	0.809	0.777	0.699	0.729	0.952
	Random Forest	0.745	0.771	0.553	0.583	0.933
	Multinomial NB	0.771	0.648	0.521	0.522	0.941
	XGBoost	0.748	0.704	0.625	0.654	0.926
	LightGBM	0.766	0.717	0.633	0.663	0.932
OpenAI Embedding (text-3-small)	Logistic Regression	0.797	0.738	0.666	0.693	0.951
	SVM (Linear)	0.798	0.751	0.685	0.711	0.951
	Random Forest	0.750	0.626	0.503	0.503	0.922
	XGBoost	0.780	0.743	0.608	0.644	0.943
	LightGBM	0.781	0.741	0.608	0.644	0.944
OpenAI Embedding (ada-002)	Logistic Regression	0.788	0.741	0.630	0.661	0.950
	SVM (Linear)	0.791	0.758	0.619	0.655	0.951
	Random Forest	0.761	0.828	0.526	0.537	0.933
	XGBoost	0.787	0.748	0.627	0.660	0.948
	LightGBM	0.788	0.742	0.627	0.661	0.949

	Model	Accuracy	Precision	Recall	F1 Score	ROC AUC
원본	Logistic Regression	0.80726	0.787021	0.665086	0.704727	0.953674
	Random Forest	0.744842	0.770915	0.552839	0.583159	0.933167
	SVM (Linear)	0.808566	0.776907	0.698505	0.72915	0.951566
	Multinomial Naïve Bayes	0.770697	0.647616	0.521419	0.522219	0.940595
	XGBoost	0.748237	0.704442	0.624776	0.65384	0.925893
	LightGBM	0.765735	0.717327	0.632927	0.663071	0.932142
오버샘플링	Logistic Regression (SMOTE)	0.802559	0.718499	0.739819	0.728063	0.950174
	Random Forest (SMOTE)	0.744842	0.70571	0.629868	0.655164	0.937508
	SVM (Linear) (SMOTE)	0.804388	0.757111	0.709704	0.730218	0.931172
	XGBoost (SMOTE)	0.749543	0.703657	0.657081	0.67625	0.926066
	LightGBM (SMOTE)	0.764429	0.707777	0.675117	0.689485	0.934525
다운샘플링	Logistic Regression (Downsampled)	0.747715	0.651722	0.765096	0.684259	0.93081
	Random Forest (Downsampled)	0.658135	0.569049	0.681635	0.591245	0.906165
	SVM (Linear) (Downsampled)	0.737268	0.635077	0.749151	0.667711	0.929967
	XGBoost (Downsampled)	0.653957	0.561428	0.669843	0.589512	0.88619
	LightGBM (Downsampled)	0.630452	0.542726	0.660077	0.57259	0.882278

예측 실제	경제/산업	군사	사회/문화/ 체육	외교	정치
경제/산업	0.877	0.001	0.088	0.001	0.033
군사	0.029	0.507	0.051	0.037	0.375
사회/문화/ 체육	0.139	0.001	0.787	0.000	0.073
외교	0.029	0.000	0.074	0.500	0.397
정치	0.051	0.020	0.084	0.022	0.822

• Test Data Set 구성

카테고리	경제/산업	군사	사회/문화/ 체육	외교	정치
개수	1,403	136	1,171	136	983

군사, 외교 카테고리의 오분류가 높은 이유:

- 1) 군사, 외교 데이터가 수가 적은 long-tailed 구조
> 군사, 외교 카테고리의 고유한 패턴을 모델이 충분히 학습하지 못함.
- 2) 모델이 기사의 summary 와 keywords 를 바탕으로한 TF-IDF로 학습하였음.
> **군사, 외교** 기사에 공통적으로 등장하는 **정치적 어휘**들이 다수 존재하여, 오분류가 집중적으로 발생.

항목	내용
평가 배경	추천의 적합성은 사용자 주관성 및 서비스 목적에 따라 달라져 단일 Accuracy로 평가하기 어려움
평가 접근	정성 평가(Human Evaluation) 결과를 정량 지표로 변환
카테고리	정치, 외교, 군사, 경제/산업, 사회/문화/체육
샘플링 방식	각 카테고리별 기사 1% 무작위 추출 (a)
추천 구성	기준 기사(a)당 추천 기사 10개 (b1-b10)
평가 기준	추천 기사 b에 대한 만족도 조사: 만족 → 1, 불만족 → 0
평가 규모	총 1,890개 기사 쌍 Human Evaluation
최종 성능	Mean Precision@10 = 0.914

● 실험 설계

항목	내용
비교 모델	OpenAI Text Embedding Model: small vs ada
실험 방식	동일 기사에 대해 추천 결과(모델별 각 5개씩 추천)를 정성 비교
실험 횟수	총 100회 (기사 랜덤 샘플링)
비교 기준	주제 일관성, 맥락 적합성
평가 방식	각 실험마다 더 우수한 모델 1개 선택 (A/B)

● 실험 결과

모델	우수 평가 횟수	비율
ada	71 / 100	71 %
small	29 / 100	29 %

[실험 2]

A or B?: [A], B는 한미해상훈련보다 공중훈련이 많아 연관성 떨어짐
기사(군사): <https://www.spnews.co.kr/news/articleView.html?idxno=101377>

[A] - small

추천1: <https://www.spnews.co.kr/news/articleView.html?idxno=22957>
추천2: <https://www.spnews.co.kr/news/articleView.html?idxno=56923>
추천3: <https://www.spnews.co.kr/news/articleView.html?idxno=93553>
추천4: <https://www.spnews.co.kr/news/articleView.html?idxno=45511>
추천5: <https://www.spnews.co.kr/news/articleView.html?idxno=92946>

[B] - ada

추천1: <https://www.spnews.co.kr/news/articleView.html?idxno=5597>
추천2: <https://www.spnews.co.kr/news/articleView.html?idxno=62212>
추천3: <https://www.spnews.co.kr/news/articleView.html?idxno=56923>
추천4: <https://www.spnews.co.kr/news/articleView.html?idxno=62574>
추천5: <https://www.spnews.co.kr/news/articleView.html?idxno=42594>

[사진: 실제 실험 과정 일부 캡처]

1. 비슷한 단어

北, 동해 수역 침범 南 어선 단속
...**인도주의적** 견지 오늘 오후 송환(종합)

⇒ **인도네시아** 외무상 일행 평양 도착
...당 80주년 경축행사 참석

⇒ 북한 주재 **인도대사관**, 독립절 맞아 연회

🔍 '**인도**' 라는 키워드에 포커싱 된 결과로 보임.

2. 세부초점 불일치

北 김정은, **베트남** 주석에 독립기념일 축전

⇒ 北 매체, 김정은 오늘(5일) 새벽 3시 평양 도착...북미회담 결렬 사실은 공개안해

🔍 기사 요약에 존재하는 '**베트남**(북미 회담 개최지)' 이라는 키워드에 포커싱 된 결과로 보임.

3. 원인 불명

동해서 北 조난어선 선원 6명 구조...동해항 이동 중

⇒ 北, 화성지구 2단계 살림집 등 대형 건설사업 집중 조명

북한주재 외교단, 평양육아원-애육원 참관

⇒ 북 김원균명칭, 평양음악무용종합대학, 민족음악발표회 개최